Domande Teoriche d'Esame

Q&A per la preparazione all'orale

GRUPPO I - SUPER-RESOLUTION

1. Perché la Super-Resolution è un problema "mal posto"?

Domanda: Secondo Hadamard, cosa definisce un problema ben posto e perché il vostro non lo è?

- **Definizione di Hadamard:** Un problema è ben posto se la soluzione *esiste*, è *unica* e dipende con *continuità* dai dati.
- **Il nostro problema ($y = Hx + e$):** È un sistema **sottodeterminato** ($M < N$). I pixel dell'immagine degradata y sono inferiori ai pixel dell'immagine ad alta risoluzione x originale che vogliamo trovare.
- **Risultato:** La soluzione **non è unica** (infinite combinazioni di pixel HR possono produrre la stessa immagine LR). Serve per forza introdurre informazioni "a priori" (Regolarizzazione o Prior neurali).

2. Total Variation vs Tichonov

Domanda: Perché nel metodo variazionale avete usato la Total Variation (TV) e non la Norma 2 (Tichonov)?

- **Tichonov (Norma 2):** Impone una omogeneità assoluta all'immagine. Questo cancella efficacemente il rumore, ma ha il difetto inesorabile di **sfocare pesantemente i contorni** degli oggetti.
- **Total Variation (TV):** Applica la Norma 1 al gradiente dell'immagine. Matematicamente assume che l'immagine sia "costante a tratti".
- **Vantaggio della TV:** Permette di **preservare i bordi netti** e i salti drastici di colore.
- **Svantaggio della TV:** Può indurre un effetto di artificialità a blocchi chiamato *staircasing* (effetto "acquerello").

3. Il meccanismo Plug-and-Play (PnP)

Domanda: Come funziona l'algoritmo Plug-and-Play all'interno di DiffPIR?

- **Concept:** I metodi PnP scompongono un'ottimizzazione difficile in due sotto-problemi più facili e iterativi.
- In DiffPIR, ogni step temporale della diffusione viene diviso esplicitamente in due fasi:
  - **Prior Step (Denoising):** La rete di diffusione pre-addestrata agisce come un denoiser puro per generare dettagli realistici partendo dal rumore corrente.
  - **Data Fidelity Step:** Un passo di ottimizzazione classico in cui si sfrutta il nostro operatore di degradazione noto $\boldsymbol{H}$ per "forzare" la coerenza tra l'immagine che si sta allucinando e l'osservazione a bassa risoluzione $\boldsymbol{y}$.

4. Rischi dei modelli Generativi (Diffusione)

Domanda: Qual è il rischio più grande nell'usare modelli Generativi (come DiffPIR) rispetto a una normale UNet?

- **UNet:** Tende a minimizzare l'errore calcolando la "media statistica" (Regression to the mean), risultando sfocata e conservativa ma sempre sicura.
- **Modelli Generativi:** Campionano la distribuzione in modo da ricreare una realtà estremamente "plausibile", introducendo dettagli ad alta frequenza che a bassa risoluzione non esistevano.
- **Il Rischio (Allucinazioni):** Se il modello generativo è troppo libero, può produrre artefatti o dettagli visivi molto realistici e convincenti, ma fisicamente **completamente falsi o inventati** rispetto al vero Ground Truth (un rischio inaccettabile, ad esempio, in campo medico).

5. Il paradosso di PSNR vs SSIM

Domanda: La UNet ha il PSNR più alto di tutti. Perché allora il risultato di DiffPIR vi sembra visivamente migliore?

- **Il PSNR (Peak Signal-to-Noise Ratio):** Si basa sull'errore quadrantico medio (MSE) calcolato brutalmente **pixel-per-pixel**. Tende a premiare immagini un po' sfocate (che stanno in media e non sbagliano troppo) rispetto a immagini con dettagli nitidi posizionati in un pixel leggermente sbagliato.
- **La percezione visiva:** Il PSNR ha una **bassa correlazione con l'occhio umano**. La UNet massimizza il PSNR ma il risultato è liscio e artificiale.
- **DiffPIR e lo SSIM:** DiffPIR ha metriche PSNR inferiori a causa di piccoli artefatti "allucinati", ma genera micro-texture percepite come molto più realistiche e definite, confermando il limite concettuale dell'affidarsi solo all'MSE.

6. L'Operatore di sfocatura nel dominio di Fourier

Domanda: Se passiamo nel dominio delle frequenze (Fourier), cosa fa esattamente l'operatore di sfocatura Gaussiana?

- **Azione del Blur:** Un filtro Gaussiano spaziale agisce esattamente come un **Filtro Passa-Basso (Low-pass filter)** nel dominio di Fourier.
- **L'effetto fisico:** Mantiene le basse frequenze (i colori generali e le masse dell'immagine) ma **taglia o attenua le alte frequenze**.
- **L'effetto visivo:** Siccome, secondo Fourier, le alte frequenze corrispondono ai bordi netti e ai micro-dettagli degli oggetti, tagliarle equivale a ottenere un'immagine sfocata in cui i contorni sono persi. L'obiettivo della Super-Resolution è proprio "inventarsi" le frequenze mancanti.

7. Velocizzare i calcoli con Fourier (FFT)

Domanda: Perché nel Data Consistency Step (o nei metodi classici) invertire l'operatore $\boldsymbol{H}$ spesso si fa sfruttando il dominio di Fourier?

- **Il Problema:** Computare una convoluzione globale nel dominio spaziale su immagini molto grandi ha una complessità temporale elevatissima.
- **La Soluzione (Teorema di Convoluzione):** Il teorema matematico afferma che una convoluzione tra due segnali nello spazio equivale a un **semplice prodotto algebrico punto-a-punto** delle loro trasformate nel dominio di Fourier.
- **Vantaggio pratico:** Sfruttando la FFT (Fast Fourier Transform), operazioni pesantissime diventano quasi istantanee (complessità abbattuta a $\boldsymbol{O(N \log_2 N)}$), rendendo la risoluzione iterativa dei problemi inversi enormemente più veloce.

8. Gestione del colore (RGB) nella Total Variation

Domanda: La Total Variation è formulata originariamente per segnali o immagini a singolo canale (grayscale). Come avete gestito le immagini a 3 canali (RGB) del vostro dataset?

- **La problematica:** Applicare la TV classica in vettoriale accoppiando i canali è matematicamente complesso. Se si usano operatori "standard" pensati per il medicale (come il Gradient di IPPy), i canali aggiuntivi vengono addirittura ignorati, corrompendo l'immagine.
- **La nostra soluzione:** Abbiamo implementato una **Channel-wise Anisotropic TV** sfruttando lo slicing tensoriale di PyTorch. Calcoliamo la divergenza in parallelo per ogni canale colore (R, G, B) in modo del tutto **indipendente**.
- **Pro e Contro:** È un approccio estremamente rapido da calcolare che ci ha permesso di evitare bug e bypassare le limitazioni degli operatori base, ma siccome penalizza i canali in modo slegato, può occasionalmente generare microscopici sfasamenti (color bleeding) in zone di forte gradiente netto.

9. Scelta di Lambda nel TV ($\lambda = 0.05$)

Domanda: Nel metodo Total Variation (TV) avete usato $\lambda = 0.05$, come lo avete scelto e perché?

- **Il ruolo di λ:** Regola il "peso" della regolarizzazione rispetto alla Data Fidelity.
- **Valori bassi (es. 0.001):** Vince la Data Fidelity. L'immagine rimarrebbe sgranata e il rumore gaussiano non verrebbe attenuato.
- **Valori alti (es. 1.0):** Vince il TV. L'algoritmo piallerebbe completamente l'immagine per azzerare i gradienti, creando un effetto acquarello estremo che distruggerebbe la geometria della chiesa.
- **Lo "Sweet Spot":** Il valore 0.05 è stato trovato empiricamente. Offre il miglior compromesso per rimuovere il rumore preservando al tempo stesso i bordi principali (macro-edges) della struttura architettonica.

10. I 50 DDIM steps di DiffPIR e le allucinazioni

Domanda: Perché avete scelto 50 step per DiffPIR? Aumentandoli a 100 o 200 non si sarebbero ridotte le allucinazioni?

- **La scelta di 50 step (DDIM):** Il modello originale DDPM richiede 1000 step, rendendo l'inferenza troppo lenta per testare un intero dataset. Usando il campionamento DDIM, 50 step rappresentano il *trade-off ideale* (ampiamente usato in letteratura) tra velocità di esecuzione e mantenimento della qualità generativa. Valori minori renderebbero il salto temporale troppo brusco.
- **Allucinazioni:** Aumentare gli step a 100 o 200 **non riduce le allucinazioni**. L'allucinazione non deriva dalla "fretta" del calcolo, ma dalla **natura mal posta del problema**. Ad alti livelli di degrado (SR=4), le informazioni ad alta frequenza sono perse per sempre. Il Prior generativo deve necessariamente "inventare" (allucinare) mattoni o finestre per rendere l'immagine fotorealistica. Più step servirebbero solo a disegnare queste allucinazioni con maggiore definizione!

11. La nostra UNet vs librerie preconfezionate (es. IPPy)

Domanda: Quali sono le differenze tecniche tra la vostra UNet implementata da zero e quelle incluse in librerie didattiche (come IPPy) usate per le TAC?

- **Gestione del colore (3 canali vs 1 canale):** La nostra UNet è inizializzata per processare i 3 canali RGB contemporaneamente in profondità (`in_channels=3`). Questo permette alla rete di imparare le correlazioni entre rosso, verde e blu per ricostruire le texture. Le reti per la TAC sono tipicamente in bianco e nero (`in_channels=1`).
- **Architettura classica vs Residuale:** Abbiamo optato per la classica U-Net (DoubleConv e Skip Connections dirette) ideale come baseline universale per Image-to-Image translation, mentre in campo medico spesso si usano reti Residuali (ResUNet) per stimare solo il rumore (residual learning).
- **L1 Loss vs L2 Loss:** Noi abbiamo addestrato la rete minimizzando l'errore assoluto (L1). La L1 perdona di più gli errori isolati e produce immagini leggermente più nitide e con contorni migliori rispetto all'errore quadratico (L2/MSE), che tende a generare un over-smoothing estremo.

12. Il nostro DiffPIR vs DiffPIR per ricostruzioni TAC

Domanda: Perché il vostro DiffPIR ha prodotto risultati eccellenti mentre lo stesso algoritmo applicato alle TAC mediche spesso fallisce miseramente?

- **La forza del Prior generativo:** Noi abbiamo sfruttato un modello di diffusione addestrato nativamente ed esplicitamente su dataset di **chiese** (`ddpm-ema-church-256`). Il Prior sapeva perfettamente com'era fatto l'oggetto. In ambito medico è difficilissimo avere modelli di diffusione potenti pre-addestrati specificamente per quello scanner TAC, portando il Prior a fallire la convergenza.
- **L'Operatore H:** Nel nostro problema (SR spaziale), l'operatore di *Data Consistency* lavora interamente nel dominio dei pixel (sfocatura e downsampling). Nelle TAC, l'operatore richiede di simulare la Trasformata di Radon (Sinogrammi) e applicare la Filtered Back Projection, rendendo il calcolo cross-dominio estremamente instabile.
- **Accettabilità:** "Allucinare" una finta finestra fotorealistica in una foto è un trade-off accettabile pur di avere un'immagine visivamente piacevole. Allucinare dettagli in una TAC medica è un pericolo assoluto.

13. Perché non addestrare la Diffusione da zero?

Domanda: Visto che avete addestrato la UNet, non sarebbe stato meglio addestrare anche il modello di diffusione da zero ai fini dell'esame?

- **Risposta:** Assolutamente no. Avrebbe violato l'essenza stessa del metodo **DiffPIR**.
- **Paradigma Plug-and-Play (PnP):** DiffPIR è un metodo *Zero-Shot*. Lo scopo teorico di questa famiglia algoritmica è dimostrare che si può prendere un modello generativo *già addestrato in modo incondizionato* e usarlo "as-is" per risolvere problemi inversi, gestendo il degrado solo matematicamente in fase di inferenza (tramite la guida H^T).
- **Limiti Computazionali:** Addestrare da zero un DDPM su immagini 256×256 richiede risorse hardware massive (cluster A100) e settimane di addestramento. Tentarlo sulle normali risorse accademiche (es. Kaggle) avrebbe portato al fallimento pratico del progetto.