Computational Imaging
Riassunto Completo – Moduli 1 e 2

Preparazione Esame Magistrale

2026

Indice

1 Fondamenti di Immagini e Computazione **2**

2 Istogrammi, Rumore e Filtri Spaziali **2**

3 Dominio delle Frequenze (Fourier) **3**

4 Imaging Computazionale e Problemi Inversi **3**

5 Regolarizzazione (Model-Based e Iterativa) **4**

6 Applicazioni Principali del Modulo 1 **4**
- 6.1 Image Deblur (Deconvoluzione) 4
- 6.2 Super Resolution (Risoluzione Spaziale) 5
- 6.3 Tomografia Computerizzata a Raggi X (CT) 5

7 Modulo 2: Dai Problemi Inversi alle Neural Imaging Pipelines **7**
- 7.1 1. Integrazione tra Ottimizzazione e Deep Learning 7
- 7.2 2. Ricostruzione non Supervisionata (Unsupervised e Self-Supervised) 7
- 7.3 3. Implicit Neural Representations (INR) e NeRF 8
- 7.4 4. Generative Imaging via Score-Based e Diffusion Models 8

8 Metriche di Valutazione delle Immagini **9**

1 Fondamenti di Immagini e Computazione

- **Image Processing vs Computer Vision vs Computer Graphics:**
  - **Image Processing:** Input (immagine) → Output (immagine modificata per migliorarne nitidezza/messa a fuoco). È un sottoinsieme della Computer Vision.
  - **Computer Vision:** Input (immagine/video) → Output (comprensione ad alto livello per automatizzare compiti del sistema visivo umano).
  - **Computer Graphics:** Creazione o manipolazione di immagini/sketch a partire da dati informatici (es. film, intrattenimento).
- **Rappresentazione Matematica:** Un'immagine reale è una funzione continua $f : \Omega \subset \mathbb{R}^2 \to \mathbb{R}$. Un'immagine digitale è la sua discretizzazione in una matrice $M \times N$. Nei formati specifici (es. medicali come DICOM, NIFTI), il file contiene una prima parte di metadati (es. info paziente) e una seconda parte con la matrice dei pixel.
- **Librerie Python: OpenCV** (fast processing/vision), **Matplotlib** (visualizzazione), **Pillow** (fotoritocco), **ImageIO** (lettura/scrittura video e immagini).
- **Compressione: Lossless** (ricostruzione esatta senza perdita) vs **Lossy** (perdita di informazioni, impossibile ricostruire l'originale).

2 Istogrammi, Rumore e Filtri Spaziali

- **Istogramma:** Grafico della distribuzione dell'intensità dei pixel (Asse X: 0-255, Asse Y: numero pixel). Concentrato a sinistra = scuro; a destra = chiaro; a campana (normale) = bilanciato. Usato per preprocessing, contrasto, segmentazione basica (soglia) ed equalizzazione.
- **Rumore (Image Noise):** Variazione casuale indesiderata nei pixel.
  - *Non correlato:* **Gaussiano** (additivo, media zero, $x_n = x + \epsilon$ con $\epsilon \simeq N(0, \sigma)$), **Uniforme**, **Esponenziale**, **Impulsivo (Salt & Pepper)** (pixel random a 0 o 1).
  - *Correlato:* **Poisson** (varianza dipende dall'intensità, tipico del medicale), **Speckle** (moltiplicativo, $x_n = x + x * \epsilon$).
- **Linear Shift Invariant Systems (LSIS):** Sistemi ottici ideali (es. le lenti si comportano come LSIS). Proprietà fondamentali:
  1. **Linearità:** $\alpha f_1 + \beta f_2 \to \alpha g_1 + \beta g_2$.
  2. **Invarianza alla traslazione:** $f(x - a) \to g(x - a)$.
- **Convoluzione 2D:** Operatore matematico alla base dei filtri lineari spaziali. Unisce l'immagine f e un kernel quadrato di lato dispari h. *Nota d'esame:* Prima dell'applicazione, il kernel viene invertito due volte rispetto al centro. Per i bordi si può: ignorarli, settare a 0 o ripetere i valori esterni.
  - *Filtri Lineari:* **Unit Impulse** (elemento neutro, restituisce l'input), **Box filter** (valore costante, satura/sfoca), **Fuzzy/Gaussiano** (smoothing regolare, decrescente dal centro).
  - *Filtri Non Lineari:* **Median filter** (ordina i pixel e prende la mediana; ottimo per il rumore *Salt & Pepper*); **Bilateral filter** (kernel Gaussiano variabile per ogni pixel basato sul contesto dei vicini, preservando i contorni).

3 Dominio delle Frequenze (Fourier)

- **Teoria di Fourier:** Ogni funzione periodica è una combinazione lineare di sinusoidi. La Trasformata di Fourier ($F(u)$) mappa il segnale dal dominio dello spazio a quello della frequenza.
- **Rappresentazione Complessa ($z = a + ib$):** La DFT genera numeri complessi per memorizzare due informazioni:
  - **Magnitudo (Ampiezza):** $|z| = \sqrt{a^2 + b^2}$ (indica *quanto* di una frequenza è presente; se modificata preservando la fase, la struttura geometrica rimane visibile).
  - **Fase:** $\phi = \arctan(b/a)$ (indica *dove* è posizionata la frequenza, definendo la struttura/bordi).
- **Proprietà d'esame fondamentali:**
  - **Alte frequenze:** Corrispondono ai contorni e ai bordi netti degli oggetti.
  - **Teorema di Convoluzione:** La convoluzione nello spazio spaziale equivale a un semplice **prodotto algebrico punto a punto** nel dominio di Fourier ($F(u) \cdot H(u)$). Permette calcoli rapidissimi tramite FFT (complessità $O(N \log_2 N)$).
  - **Filtraggio in frequenza:**
    - *Low-pass (Passa-basso):* Elimina il rumore ad alta frequenza ma rende l'immagine sfocata. Per mitigare gli artefatti da risonanza del filtro ideale (oscillazioni), si usano transizioni graduali.
    - *High-pass (Passa-alto):* Rimuove le aree a luminosità costante mettendo in evidenza i bordi.

4 Imaging Computazionale e Problemi Inversi

- **Definizione:** Sistemi di acquisizione in cui i dati misurati (y) non sono immagini dirette, ma misurazioni indirette o incomplete. Si stima l'oggetto incognito x invertendo il modello in avanti (forward model) $\mathcal{F}$ che descrive la fisica dello strumento:

$$y = \mathcal{F}x + e \tag{1}$$

- **Problema Diretto vs Inverso:** Il problema diretto calcola l'effetto data la causa (orientamento causa-effetto, tipicamente con perdita di informazioni). Il problema inverso risale alle cause dati gli effetti.
- **Mal-condizionamento (Ill-posedness secondo Keller/Hadamard):** Un problema si dice ben posto se la soluzione *esiste*, è *unica* e *dipende con continuità dai dati*. I problemi inversi lineari di imaging ($Ax = y + e$) sono mal posti perché la matrice di sistema A è mal condizionata:
  1. **Se $M = N$ (quadrata e non singolare):** La soluzione esiste ed è unica, ma non è continua. Un piccolo rumore sui dati viene amplificato a dismisura, rendendo la *naive solution* fisicamente inaccettabile.
  2. **Se $M > N$:** Il sistema è sovradeterminato (nessuna soluzione); si risolve tramite i minimi quadrati: $\min ||Ax - (y + e)||_2^2$.
  3. **Se $M < N$:** Il sistema è sottodeterminato (infinite soluzioni); si ricorre comunque ai minimi quadrati.

5 Regolarizzazione (Model-Based e Iterativa)

Per curare l'ill-posedness si cercano soluzioni approssimate inserendo informazioni *a priori* (vincoli fisici o regolarizzazioni).

- **Formulazione Unconstrained (Non vincolata):**

$$\min_x d(Ax, y) + \lambda R(x) \tag{2}$$

  - $d(Ax, y)$: Termine di **Data Fitting**. Nel caso di rumore Gaussiano, si usa la norma 2 al quadrato: $||Ax - y||_2^2$.
  - λ: Parametro di regolarizzazione. Se troppo piccolo la soluzione resta rumorosa; se troppo grande, le caratteristiche del vincolo dominano distorcendo l'immagine.
  - $R(x)$: Funzione di regolarizzazione che impone i vincoli sulla soluzione.

- **Tipologie di Regolarizzatori $R(x)$:**

  1. **Norma 2 (Tichonov):** $R(x) = ||x||_2^2$. Impone omogeneità (*smoothness*) rendendo il vettore uniforme. È strettamente convessa, risolvibile in modo esatto tramite le equazioni normali $A^TAx = A^Ty$ con l'algoritmo CGLS. Limite: cancella il rumore ma sfoca i contorni degli oggetti.
  2. **Norma 1 (Sparsificante):** Impone che l'immagine sia rappresentabile con pochissimi componenti significativi non nulli. È una funzione convessa ma non derivabile nello zero. Spesso associata a vincoli di non negatività ($x \geq 0$).
  3. **Total Variation (TV):** Applica la Norma 1 al **Gradiente** dell'immagine ($\nabla f = (\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y})$). Assume che le immagini siano costanti a tratti (zone omogenee divise da bordi netti). Poiché non è differenziabile nello zero ed è convessa, si approssima con un parametro liscio o si risolve tramite **algoritmi di prossimità** (es. *Chambolle-Pock*) senza calcolare il gradiente. Limite: induce l'effetto *staircasing* (immagini a blocchi artificiali).
  4. **Norma p ($0 < p < 1$) e Norma 0:** Impongono una sparsità estrema. Sono funzioni **non convesse**. *Nota d'esame:* Avendo molteplici minimi locali, l'algoritmo converge a una soluzione che dipende fortemente dalla scelta dell'iterato iniziale x_0.

- **Regolarizzazione Iterativa:** Consiste nel risolvere il puro problema di data fit ($\min ||Ax - y||_2^2$) mediante un metodo iterativo e **interrompere anticipatamente le iterazioni** (early stopping) al punto minimo della curva di errore, sfruttando il fenomeno della semi-convergenza prima che il rumore esploda.

- **Scelta del parametro λ:**

  - *Principio di Discrepanza:* Lavora a posteriori; richiede una stima del rumore e e seleziona la soluzione che eguaglia la discrepanza al livello di rumore stimato (semplice ma tende a sovrastimare).
  - *Scelta Euristica:* Metodo "trial and error" basato su simulazioni con dati noti; si traccia la curva dell'errore relativo rispetto a λ e si sceglie il punto di minimo.

6 Applicazioni Principali del Modulo 1

6.1 Image Deblur (Deconvoluzione)

- **Modello:** $y = K * x + e$, dove K rappresenta la **PSF (Point Spread Function)**, ovvero il kernel che descrive come il sistema ottico diffonde la luce di un singolo punto. Si assumono PSF *Space Invariant* (identiche su tutta l'immagine).

- **Risoluzione in frequenza:** Nel caso ideale senza rumore, la deconvoluzione è una semplice divisione punto a punto in Fourier: $F'(u,v) = G(u,v)/H(u,v)$. In presenza di rumore, questa operazione amplifica a dismisura le alte frequenze distruggendo l'immagine; si rende perciò obbligatorio l'uso della regolarizzazione (Tichonov o TV).
- **Blind Deconvolution:** Caso reale in cui la PSF K non è nota. Richiede la stima simultanea di kernel e immagine; i metodi model-based classici falliscono e oggi si usano quasi solo reti neurali.

6.2 Super Resolution (Risoluzione Spaziale)

- **Modello Inverso:** $y_k = DB_k x + n_k$, dove si combinano la sfocatura ottica (B_k), l'operatore di **Downsampling** (D) che riduce la dimensione della matrice scartando dati, e il rumore stocastico (n_k).
- **Operatori di Downsampling (D):** *Zero-padding* (agisce come selettore, estraendo un solo pixel per blocco e scartando gli altri) oppure *Media* (calcola la media aritmetica del blocco, modellando fedelmente i sensori fisici).
- **Tecniche di Interpolazione (Upscaling):**
  - *Nearest Neighbour:* Replica semplicemente il valore del pixel più vicino. Molto veloce ma produce immagini pixelate/a blocchi senza aggiungere dettagli reali.
  - *Bilineare:* Media pesata dei 4 pixel più vicini tramite un polinomio di grado 1 applicato nelle due direzioni (x e poi y). Più fluida ma permane una leggera sfocatura.
  - *Bicubica:* Sfrutta un vicinato 4×4 (16 pixel) con polinomi cubici di grado 3. Garantisce immagini più nitide e contorni decisamente più definiti.

6.3 Tomografia Computerizzata a Raggi X (CT)

- **Principio:** Imaging per sezioni trasversali (fette o *slices*) basato sui profili di attenuazione dei Raggi X legati alla densità dei tessuti.
- **Sinogramma:** Insieme dei dati grezzi (*raw data*) registrati dai sensori lungo lo spazio del rilevatore t e l'angolo di rotazione θ. Viene campionato discretamente in punti t_i e angoli θ_k. È affetto da due sorgenti di rumore: **Poisson** (Shot noise dovuto alla natura statistica dei fotoni della sorgente) e **Gaussiano** (White noise termico a media nulla dovuto all'elettronica dei detector).
- **Metodi di Ricostruzione Analitici:**
  - *Simple Back Projection (Retroproiezione semplice):* Spalma i profili di attenuazione sulla griglia vuota. Genera un grave artefatto matematico intrinseco: una vistosa sfocatura a raggiera attorno all'oggetto.
  - *Filtered Back Projection (FBP):* Applica un filtro matematico (tipicamente un filtro passa-alto) ai profili nel dominio delle frequenze (Fourier) prima di retroproiettarli, eliminando le scie e definendo i bordi. Fallisce se i dati sono incompleti o degradati.
- **Protocolli di Sicurezza (ALARA) e Geometrie Incomplete:** Per minimizzare la dose di radiazioni ionizzanti si ricorre a scansioni volutamente degradate:
  1. *Low-dose CT:* Mantiene la geometria completa ma riduce la potenza del raggio; la soluzione soffre di una forte **instabilità** dovuta all'amplificazione del rumore massiccio.

2. *Sparse-view CT:* Scansioni rade con un grande passo angolare; mancano equazioni nel sistema matematico determinando la **non-unicità** della soluzione (infinite immagini possibili), generando i cosiddetti **streak artifacts** (artefatti a striscia).
3. *Limited-angle CT / Tomosintesi:* Copre solo un arco parziale senza completare il giro attorno al paziente. Provoca una gravissima distorsione geometrica dovuta al problema del cuneo di frequenze mancante (**missing wedge problem**), impedendo la ricostruzione dei bordi paralleli ai raggi mancanti.

- **CT como Problema Inverso Model-Based:** Nei casi degradati sopra descritti si abbandona la FBP e si modella la CT come un gigantesco sistema algebrico lineare discretizzato $Ax = m$.
  - m: Vettore del sinogramma misurato.
  - x: Immagine vettorizzata in cui ogni cella rappresenta il coefficiente di attenuazione locale del voxel.
  - A: Matrice di sistema contenente i pesi geometrici dei raggi $a_{i,j}$. I coefficienti si calcolano tramite due approcci:
    1. **Ray driven:** Si traccia il raggio matematico sorgente-pixel; il peso $a_{i,j}$ è il rapporto tra la lunghezza del segmento interno al voxel e la lunghezza totale del raggio.
    2. **Pixel/Voxel driven:** Si proietta il singolo voxel come un'ombra sul rilevatore; il peso si ottiene dividendo l'area dell'ombra proiettata per l'area totale del sensore.

7 Modulo 2: Dai Problemi Inversi alle Neural Imaging Pipelines

Il paradigma variazionale classico viene integrato, potenziato o sostituito dall'uso delle reti neurali profonde, che elaborano i dati strutturati in tensori.

7.1 1. Integrazione tra Ottimizzazione e Deep Learning

Esistono diverse strategie per combinare la conoscenza fisica del problema (Forward Model K) con il Deep Learning:

- **Supervised Post-Processing (End-to-End):** Si calcola prima una ricostruzione preliminare approssimata ed economica tramite un metodo classico (es. la *naive solution* invertendo K, oppure la FBP nella tomografia). Questa immagine grezza, tipicamente affetta da pesanti artefatti o rumore, viene passata in input a una rete neurale (es. U-Net) addestrata per mappare l'immagine corrotta nel corrispettivo *Ground Truth* pulito.
- **Plug-and-Play (PnP) Methods:** Si basa su algoritmi di scomposizione della funzione obiettivo (es. **ADMM** o **HQS - Half Quadratic Splitting**). Questi algoritmi separano la minimizzazione in due sotto-problemi iterativi alternati:
  1. *Data Fidelity Step:* Risolve un passo di ottimizzazione classico legato alla coerenza dei dati (sfruttando l'operatore noto K).
  2. *Prior Step (Proximal Operator):* Matematicamente equivalente a un'operazione di **denoising**. Nei metodi PnP, questo operatore formale viene rimpiazzato direttamente da una rete neurale denoiser pre-addestrata (es. DnCNN). La convergenza matematica del ciclo completo non è sempre garantita ed è legata alla Lipschitzianità della rete.
- **Algorithm Unfolding (Unrolling):** Consiste nel prendere un algoritmo di ottimizzazione iterativo classico (es. **ISTA** - Iterative Shrinkage-Thresholding Algorithm o **Gradient Descent**) troncato a un numero fisso T di iterazioni (es. $T = 10$). Ciascuna iterazione viene srotolata e mappata come se fosse un singolo strato (layer) di una rete neurale profonda. I parametri dell'algoritmo (come il passo di discesa α o le soglie di sparsità) diventano parametri computazionali appresi tramite backpropagation durante l'addestramento. Vantaggio: unisce l'esplicita coerenza fisica del modello alla flessibilità dei dati.

7.2 2. Ricostruzione non Supervisionata (Unsupervised e Self-Supervised)

Quando non si dispone di un dataset di immagini Ground Truth (immagini perfettamente pulite, frequente in campo medico), si ricorre a strategie alternative:

- **Self-Supervised Learning (es. Noise2Noise):** Dimostra matematicamente che è possibile addestrare una rete neurale a denoisare immagini disponendo soltanto di coppie di acquisizioni diverse della *stessa* scena, entrambe corrotte da rumore indipendente a media nulla. La rete, non potendo prevedere la componente casuale e incoerente del rumore, converge sul target comune pulito (la media statistica).
- **Deep Image Prior (DIP):** Approccio radicalmente diverso: **non richiede alcun dataset di addestramento**. Si usa una rete neurale convoluzionale (CNN) generativa G_θ per ricostruire una *singola* specifica immagine. L'input della rete è un vettore di rumore fisso z. L'ottimizzazione avviene ottimizzando i pesi θ della rete stessa per minimizzare la discrepanza con i dati misurati:

$$\min_\theta ||K(G_\theta(z)) - y||_2^2 \tag{3}$$

Il principio cardine (Prior Implicito) si basa sul fatto che le CNN sono spettralmente inclinate: preferiscono apprendere e ricostruire prima le strutture coerenti e a bassa frequenza (le forme reali dell'immagine) e solo dopo molte iterazioni memorizzano le alte frequenze caotiche (il rumore). Interrompendo anticipatamente l'ottimizzazione dei pesi (*early stopping*), si ottiene l'immagine pulita.

7.3 3. Implicit Neural Representations (INR) e NeRF

Un cambio di paradigma nella rappresentazione digitale:

- **INR:** Invece di memorizzare un'immagine come una matrice discreta di pixel, la scena viene modellata come una funzione continua implementata da un perceptrone multistrato (MLP) f_θ. La rete prende in input le coordinate spaziali continua (x, y) (e possibilmente temporali t) e restituisce in output il valore di intensità o colore del pixel.
- **NeRF (Neural Radiance Fields):** Estensione delle INR alla ricostruzione 3D a partire da immagini 2D scattate da diverse angolazioni conosciute. Un MLP mappa una coordinata 3D e una direzione di vista (x, y, z, θ, ϕ) in una densità volumetrica σ e un colore RGB. L'immagine 2D finale si ottiene tramite l'operatore fisico differenziabile di **Volume Rendering** applicato lungo i raggi ottici. L'addestramento ottimizza i pesi del MLP confrontando i pixel renderizzati con quelli delle foto reali. Per catturare i dettagli ad alta frequenza (evitando che la rete produca immagini troppo sfuocate), è indispensabile mappare l'input spaziale in uno spazio a frequenza più alta tramite il **Positional Encoding** prima di passarlo al MLP.

7.4 4. Generative Imaging via Score-Based e Diffusion Models

Rappresentano lo stato dell'arte per campionare immagini dalla distribuzione a priori (*Prior* Bayesiano) e risolvere problemi inversi.

- **Forward Process (Noising):** Un'immagine pulita x_0 viene progressivamente distrutta aggiungendo rumore Gaussiano su T passi discreti (o tramite un'equazione differenziale stocastica SDE continua), fino a trasformarla completamente in rumore bianco x_T.

  Reverse Process (Denoising): Una rete neurale (tipicamente una U-Net) viene addestrata a stimare il rumore aggiunto a ogni passo, permettendo di invertire il processo partendo dal rumore puro per generare un'immagine realistica.

- **Risoluzione di Problemi Inversi via Modelli di Diffusione:** Per condizionare la generazione in modo che l'immagine finale sia coerente con le nostre misurazioni reali y (es. un sinogramma o un'immagine sfocata), si interviene durante la traiettoria di campionamento inverso modificando ogni iterato x_t:

  1. **Diffusion Posterior Sampling (DPS):** Ad ogni passo della diffusione, si calcola il gradiente del termine di data fidelity $||K(x_t) - y||_2^2$ rispetto allo stato corrente x_t. Questo gradiente viene sommato alla stima del denoiser per direzionare attivamente la traiettoria verso la coerenza con i dati misurati.
  2. **DiffPIR (Diffusion Plug-and-Play):** Alterna esplicitamente un passo standard di denoising affidato alla rete di diffusione pre-addestrata e un passo di ottimizzazione variazionale classico per far quadrare i dati con il modello K.

- **Trade-off e Limitazioni Critiche d'Esame:** I modelli di diffusione sono generatori potentissimi ma presentano rischi strutturali: se il passaggio di denoising è troppo dominante, la rete può **allucinare** dettagli visivi estremamente realistici e convincenti,

ma fisicamente **falsi o errati** (pericolo assoluto in campo medico). Se il passaggio di coerenza dei dati è invece troppo marcato, la ricostruzione può esibire artefatti oscillatori o eccessivamente levigati (*oversmoothed*). La valutazione quantitativa rigorosa della coerenza dei dati resta quindi imprescindibile.

8 Metriche di Valutazione delle Immagini

Tabella 1: Confronto delle Metriche di Valutazione di Output

Metrica	Caratteristiche Principali	Limiti / Vantaggi
MSE	$MSE = \frac{1}{N}\sum_{i=1}^{N}(x_i - x_i^{GT})^2$ Più è basso, migliore è l'immagine.	Molto semplice; bassa correlazione con la qualità visiva; sensibile alla scala.
PSNR	$PSNR = 10\log_{10}\left(\frac{\max(x)^2}{MSE}\right)$ Più è alto, migliore è l'immagine.	Espresso in dB (ottimo $\approx$ 30–40 dB). Standard di confronto perché indipendente dalla scala.
SSIM	Non ha una formula elementare. Sensibile a contrasto e struttura.	**Altamente informativo**; fortemente correlato con l'ispezione visiva umana.
CNR	Specifico per l'imaging medico.	Misura il rapporto contrasto-rumore nelle regioni d'interesse

Riferimenti bibliografici

[1] Appunti di Teoria, *Sottoinsiemi di Computer Vision*, Modulo 1.

[2] Documentazione sulle Immagini Digitali, *Rappresentazione Continua e Discreta*.

[3] Analisi del Rumore, *Modelli Statistici di Noise nelle Immagini*.

[4] Teoria dei Sistemi, *Linear Shift Invariant Systems (LSIS)*.

[5] Piccolomini, *Definizione di Computational Imaging e Problemi Inversi*.

[6] Keller, *Definizione e Proprietà dei Problemi Inversi*.

[7] Tichonov, *Metodi di Regolarizzazione Classica e Ottimizzazione Convessa*.

[8] Chambolle-Pock, *Algoritmi di Prossimità per la Total Variation*.

[9] Teoria della TAC, *Dalla Retroproiezione alla Filtered Back Projection (FBP)*.

[10] Appunti Modulo 2, *Metodi Plug-and-Play e Deep Image Prior per Problemi Inversi*.

[11] Modelli Generativi, *SDE e Scomposizione Posteriore nei Modelli di Diffusione*.